

Projekt z przedmiotu MED

Informacje kontaktowe

dr inż. Robert Bembenik, pok. 301, tel. 7715, email: robert.bembenik@pw.edu.pl

Konsultacje projektowe odbywają się we wtorki w godzinach 16.00-17.45. Preferowany sposób konsultacji: zdalne, z wykorzystaniem aplikacji MsTeams. Aby umówić się na spotkanie przez MsTeams w godzinach konsultacji projektowych proszę o wcześniejszą informację przez czat, lub o przesłanie emaila w tej sprawie.

Cel projektu

Celem projektu jest zbadanie własności zaimplementowanego przez siebie algorytmu:

- czas wykonania dla różnych wartości parametrów wejściowych,
- wpływ zmiany wartości parametrów na uzyskiwane wyniki,
- skalowalność algorytmu względem rozmiaru danych (liczby rekordów oraz liczby atrybutów),
- oraz cele szczegółowe, jeśli są podane w opisie zadania.

Testy należy przeprowadzić dla kilku zbiorów danych.

Strona domowa projektu

<https://leon.pw.edu.pl/course/view.php?id=3797>

Środowisko deweloperskie

Wybór języka programowania oraz narzędzi i bibliotek należy do wykonawcy zadania, ograniczeniem jest tu legalność wykorzystania wybranych narzędzi/bibliotek do realizacji projektów studenckich. Preferowane są popularne języki programowania.

Liczność grup

Zadania są pomyślane jako jednoosobowe (chyba, że wskazano inaczej), jednak istnieje możliwość ich realizacji w grupie maksymalnie dwuosobowej. W takim przypadku należy ustalić z prowadzącym zakres zadania projektowego.

Ważne daty

21.04.2026 – termin wyboru tematu projektu.

- Proszę przesłać emailiem swoje preferencje projektowe, w temacie wiadomości proszę dodać **[projekt MED]**.
- Proszę uwzględnić w wiadomości 3 preferowane tematy w kolejności preferencji. Projekty zostaną przydzielone zgodnie z kolejnością zgłoszeń i preferencjami.
- Dla projektów realizowanych przez zespoły proszę o adresowanie wiadomości do wszystkich członków zespołu.
- Osoby, które nie prześlą preferencji w wyznaczonym terminie zostaną przypisane do tematu projektu arbitralnie wybranego przez prowadzącego.

08.05.2026 – kluczowe elementy rozwiązania/projekt implementacji (część 1) powinien zawierać informacje m.in. o strukturze implementacji (funkcje, klasy) z odniesieniem do konkretnych kroków

implementowanego algorytmu, strukturach danych wykorzystywanych do przechowywania danych źródłowych oraz struktur wykorzystywanych w implementacji algorytmu oraz ocenę efektywności proponowanego rozwiązania. Projekt implementacji nie jest implementacją.

Kluczowe elementy rozwiązania należy przedstawić osobiście w trakcie spotkania w terminie konsultacji projektowych. Przedstawienie obejmuje:

- przedstawienie zakresu, wybranych technologii do realizacji zadania oraz planów testów w formie prezentacji (np. w formacie .ppt);
- omówienie projektu implementacji algorytmu (należy przygotować odpowiednią dokumentację).

Przed prezentacją należy uzgodnić z prowadzącym dokładny termin oraz wgrać odpowiednio wcześniej dokumentację projektu implementacji algorytmu.

02.06.2026 – ostateczny termin oddania całego projektu (część 2) w terminie konsultacji projektowych. Oddanie projektu obejmuje:

- prezentację pokazującą główne zagadnienia związane z realizowanym projektem – należy przygotować prezentację (np. w formacie .ppt);
- pokaz działania oprogramowania;
- rozmowę dotyczącą testów, uzyskanych wyników i wniosków.

Przed oddaniem projektu należy uzgodnić z prowadzącym dokładny termin oraz wgrać odpowiednio wcześniej dokumentację projektu implementacji algorytmu.

Zasady zaliczenia projektu

Maksymalna liczba punktów z części 1 wynosi 15, a z części 2 wynosi 30 (sumaryczna maksymalna liczba punktów do uzyskania z obu części wynosi 45). Uzyskane z projektu punkty zostaną przeliczone na procent całkowitej możliwej do uzyskania liczby punktów. Wartość ta będzie podstawą do wyliczenia oceny końcowej.

Dokumentacja

Dokumentacja końcowa powinna zawierać następujące rozdziały:

1. Wprowadzenie i definicja problemu
2. Charakterystyka proponowanego algorytmu/rozwiązania z odniesieniem do literatury
3. Opis implementacji
4. Instrukcja użytkownika (jak uruchomić/korzystać z implementacji)
5. Charakterystyka wykorzystywanych zbiorów danych
6. Wyniki eksperymentów pokazujących właściwości proponowanego rozwiązania
7. Wnioski
8. Bibliografia
9. Kod źródłowy w osobnym pliku(ach).

Eksperymenty należy przeprowadzić z wykorzystaniem publicznie dostępnych zbiorów danych, np.:

- <https://archive.ics.uci.edu/datasets>,
- <http://fimi.uantwerpen.be/data/>,
- <https://github.com/deric/clustering-benchmark>,

- <http://www.philippe-fournier-viger.com/spmf/index.php?link=datasets.php>

Obydwie części dokumentacji należy zamieścić na serwerze

<https://leon.pw.edu.pl/course/view.php?id=3797> w terminach przedstawionych powyżej.

Proponowane tematy

0. *Temat własny – wymaga uzgodnienia*

1. *Reguły asocjacyjne*

Implementacja jednego z algorytmów opisanych w artykułach:

- 1.1 Thanh-Long Nguyen, Bay Vo, Vaclav Snasel, Efficient algorithms for mining colossal patterns in high dimensional databases, 2017, Knowledge-Based Systems.
- 1.2 Ezeife, C.I., Su, Y. (2002). Mining Incremental Association Rules with Generalized FP-Tree. In: Cohen, R., Spencer, B. (eds) Advances in Artificial Intelligence. Canadian AI 2002. Lecture Notes in Computer.
- 1.3 Jiawei Han and Yongjian Fu, "Mining multiple-level association rules in large databases," in IEEE Transactions on Knowledge and Data Engineering, vol. 11, no. 5, pp. 798-805, Sept.-Oct. 1999, doi: 10.1109/69.806937.
- 1.4 Han, J., Pei, J., Yin, Y. (2000). Mining frequent patterns without candidate generation. Proceedings of the 2000 ACM SIGMOD International Conference on Management of Data, 1–12

2. *Równoległe algorytmy wykrywania reguł asocjacyjnych*

Implementacja jednego z algorytmów opisanych w artykułach:

- 2.1 R. Agrawal and J. Shafer, "Parallel Mining of Association Rules, IEEE Transactions On Knowledge And Data Engineering, Vol 8, No 6, December 1996
- 2.2 Mohammed J. Zaki, Srinivasan Parthasarathy, Wei Li, A Localized Algorithm for Parallel Association Mining, 9th Annual ACM Symposium on Parallel Algorithms and Architectures (SPAA), pp 321-330, Newport, Rhode Island, June 22-25, 1997.

3. *Wzorce sekwencyjne*

Implementacja jednego z algorytmów do odkrywania częstych wzorców sekwencyjnych: GSP (uogólniony), SPADE, PrefixSpan, ERMiner.

- 3.1. R. Srikant, R. Agrawal, "Mining sequential patterns: Generalizations and performance improvements," In Proceedings of International Conference on Extending Database Technology,
- 3.2. Zaki, M. J., "SPADE: An efficient algorithm for mining frequent sequences", Machine learning, vol.42.no.1-2,pp.31-60,2001,

- 3.3. Pei, J., Han, J., Mortazavi-Asl, B., Pinto, H., Chen, Q., Dayal, U., Hsu, M., "Mining Sequential Patterns by Pattern-Growth: The PrefixSpan Approach", IEEE Trans. Knowledge and Data Engineering,
- 3.4. Fournier, P., Zida, S., Guenieche, T. and Tseng V., "ERMiner: Sequential Rule Mining using Equivalence Classes", Advanced in intelligent data Analysis

4. Grupowanie

Implementacja jednego z algorytmów przedstawionych poniżej.

- 4.1. Guha S., Rastogi R., Shim K., ROCK: A robust clustering algorithm for categorical attributes, Proceedings of the International Conference on Data Engineering, Sydney 1999, pp. 512–521.
- 4.2. Karypis G., Han E., Kumar V., CHAMELEON: A hierarchical clustering algorithm using dynamic modeling, IEEE Computer: Special Issue on Data Analysis and Mining, vol. 32, no. 8, 1999, pp. 68–75.
- 4.3. S. Zhou, Y. Zhao, J. Guan, and J. Huang, "A Neighborhood-Based Clustering Algorithm," in Advances in Knowledge Discovery and Data Mining
- 4.4. Raymond T.Ng, J.Han: CLARANS: A method for clustering objects for spatial data mining 2002 IEEE Transactions on Knowledge and Data Engineering
- 4.5. Estivill-Castro V., Lee I.: AUTOCLUST: automatic clustering via boundary extraction for mining massive point-data sets, Proceedings of the 5th International Conference on Geocomputation, 2000
- 4.6. Zhang T., Ramakrishnan R., Linvy M., BIRCH: an efficient data clustering method for very large databases, Proc. ACM SIGMOD Int. Conf. on Management of Data, ACM Press, 1996, pp. 103–114.
- 4.7. Kryszkiewicz M., Lasek P. (2010) A Neighborhood-Based Clustering by Means of the Triangle Inequality. In: Fyfe C., Tino P., Charles D., Garcia-Osorio C., Yin H. (eds) Intelligent Data Engineering and Automated Learning – IDEAL 2010. IDEAL 2010

5. Klasyfikacja

Sugerowana liczba osób w grupie: 2.

Implementacja i porównanie algorytmów klasyfikacji: Naïve Bayesian Classifier, Lazy Classification, SPRINT.

- Jiawei Han, Micheline Kamber, and Jian Pei. 2011. Data Mining: Concepts and Techniques (3rd ed.). Morgan Kaufmann Publishers Inc., San Francisco, CA, USA
- John C. Shafer, Rakesh Agrawal, and Manish Mehta. 1996. SPRINT: A Scalable Parallel Classifier for Data Mining. In Proceedings of the 22th International Conference on Very Large Data Bases (VLDB '96)

6. Odkrywanie zbiorów wysokiej użyteczności

Implementacja jednego z algorytmów odkrywania zbiorów wysokiej użyteczności: Two-Phase, UP-Growth lub HUI-Miner.

Cele szczegółowe: Porównanie podejścia opartego na wsparciu i na użyteczności, analiza wpływu progu utility na liczbę wzorców, czas działania i praktyczną interpretację wyników.

- 6.1. Two-Phase: Liu, Y., Liao, W.-K., Choudhary, A. (2005). A two-phase algorithm for fast discovery of high utility itemsets. In *Advances in Knowledge Discovery and Data Mining*, 689–695.
- 6.2. UP-Growth: Tseng, V. S., Wu, C.-W., Shie, B.-E., Yu, P. S. (2010). UP-Growth: An efficient algorithm for high utility itemset mining. *Proceedings of the 16th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 253–262.
- 6.3. HUI-Miner: Liu, M., Qu, J. (2012). Mining high utility itemsets without candidate generation. *Proceedings of the 21st ACM International Conference on Information and Knowledge Management*, 55–64.

7. Wnioskowanie z niepełnych danych i wiedzy częściowej

Implementacja wybranego podejścia do klasyfikacji lub wnioskowania przy brakujących danych, np. z wykorzystaniem zbiorów przybliżonych, reguł decyzyjnych dla danych niekompletnych albo porównania z metodami imputacji.

Cele szczegółowe: Ocena odporności algorytmu na różny poziom niekompletności danych oraz porównanie jakości wnioskowania przy różnych strategiach obsługi braków.

- 7.1. Rough-set dla danych niekompletnych: Kryszkiewicz, M. (1998). Rough set approach to incomplete information systems. *Information Sciences*, 112(1–4), 39–49.
- 7.2. MLEM2 dla danych z brakami: Grzymala-Busse, J. W., Hu, M. (2000). A comparison of several approaches to missing attribute values in data mining. In *Rough Sets and Current Trends in Computing*, 340–347.
- 7.3. Imputacja kNN: Troyanskaya, O., Cantor, M., Sherlock, G., Brown, P., Hastie, T., Tibshirani, R., Botstein, D., Altman, R. B. (2001). Missing value estimation methods for DNA microarrays. *Bioinformatics*, 17(6), 520–525.